固定向量正交投影与 IsoHC 的数学推导

从 stabilizer polar projection 到 invariant-preserving residual mixing

整理稿，用于论文验证

2026 年 5 月 10 日

摘要

本文将 IsoHC 中的残差流混合约束抽象为一个通用数学问题：给定非零向量 $v \in \mathbb{R}^n$，如何把任意矩阵 $A \in \mathbb{R}^{n\times n}$ 投影到保持 v 不变的正交流形

$$\mathcal{M}_v = \{Q \in O(n) : Qv = v\}.$$

该集合是正交群 $O(n)$ 中固定向量 v 的 stabilizer subgroup，并与 $O(n-1)$ 同构。本文给出完整推导：其元素可分解为

$$Q = \hat{v}\hat{v}^\mathsf{T} + URU^\mathsf{T}, \qquad R \in O(n-1),$$

其中 $\hat{v} = v/\|v\|_2$，U 是 $v^\perp$ 的任意正交基。进一步证明 Frobenius 范数下的最近点投影可写为

$$\Pi_v(A) = \hat{v}\hat{v}^\mathsf{T} + U\ \mathrm{polar}(U^\mathsf{T}AU)\,U^\mathsf{T}.$$

该公式与 U 的具体选择无关；当 $U^\mathsf{T}AU$ 满秩时投影唯一；当其奇异时最近点可能不唯一，但任意极分解正交因子仍给出最优解。

第二章将该理论专门化到 IsoHC。令 $v = \mathbf{1}$，则 $Q\mathbf{1} = \mathbf{1}$ 与正交性共同保证 residual stream mean 与 channel-wise stream energy 的精确保留。有限步 Newton-Schulz 只给出近似正交因子，因此本文将 exact polar projection 与 practical NS implementation 分开陈述，并给出相应误差界。

目录

第一章 数学推导：固定向量正交投影 **1**

1.1 问题定义与目标 1

1.2 基本记号与子空间分解 1

1.3 Stabilizer 分解定理 2

1.4 Frobenius 最近点投影 3

1.5 保持不变量与等距性质 5

1.6 有限步 Newton-Schulz 实现与误差界 6

1.6.1 Newton-Schulz polar iteration 6

1.6.2 近似投影的结构误差 6

1.7 非负性、正交性与随机性的不可兼得 8

1.8 多不变量方向的推广 8

第二章 IsoHC：从通用投影到残差流等距混合 **10**

2.1 Hyper-Connections 中的稳定性问题 10

2.2 IsoHC 流形定义 10

2.3 IsoHC 的精确不变量 11

2.4 Iso-NS: stabilizer polar projection 的实现 11

2.5 Iso-NS 的误差传递到 IsoHC 12

2.6 残差路径上的梯度保持 13

2.7 与 mHC 的几何差异 13

2.8 论文中建议的理论表述 14

2.9 需要在实验或实现中验证的点 15

2.10 本推导没有声称的内容 15

结论 **16**

第一章　数学推导：固定向量正交投影

1.1　问题定义与目标

考虑一个非零向量 $v \in \mathbb{R}^n$。我们关心如下矩阵集合:

$$\mathcal{M}_v := \{Q \in \mathbb{R}^{n\times n} : Q^\mathsf{T} Q = I,\ Qv = v\}. \tag{1.1}$$

等价地，$\mathcal{M}_v$ 是正交群 $O(n)$ 中固定 v 的稳定子群:

$$\mathcal{M}_v = \mathrm{Stab}_{O(n)}(v). \tag{1.2}$$

目标是为任意 unconstrained matrix $A \in \mathbb{R}^{n\times n}$ 构造一个可微、可计算、尽量接近 A 的 $Q \in \mathcal{M}_v$。核心优化问题是

$$\min_{Q\in\mathcal{M}_v} \|A - Q\|_F^2 . \tag{1.3}$$

该问题的机器学习含义是：学习一个线性混合矩阵时，要求某个已知方向 v 是严格不变量，同时要求整体变换不放大也不缩小欧氏能量。

注 1.1 (与 IsoHC 的关系)**.** IsoHC 是 (1.1) 的特例，取 $v = \mathbf{1}$。此时 $Q\mathbf{1} = \mathbf{1}$ 表示 residual stream 的 constant/mean direction 被固定；正交性表示所有 stream 方向上的 ℓ_2 能量被保留。

1.2　基本记号与子空间分解

令

$$\hat{v} := \frac{v}{\|v\|_2}, \qquad P_v := \hat{v}\hat{v}^\mathsf{T}, \tag{1.4}$$

其中 P_v 是到一维子空间 $\mathrm{span}\{v\}$ 的正交投影。

令 $U \in \mathbb{R}^{n\times(n-1)}$ 是 $v^\perp$ 的任意正交基，即

$$U^\mathsf{T} U = I_{n-1}, \qquad U^\mathsf{T}\hat{v} = 0. \tag{1.5}$$

于是

$$P_v + UU^\mathsf{T} = I_n. \tag{1.6}$$

这给出了正交直和分解

$$\mathbb{R}^n = \operatorname{span}\{v\} \oplus v^\perp. \tag{1.7}$$

任意 $x \in \mathbb{R}^n$ 可唯一写成

$$x = \alpha\hat{v} + Uy, \qquad \alpha = \hat{v}^\mathsf{T} x, \qquad y = U^\mathsf{T} x. \tag{1.8}$$

且

$$\|x\|_2^2 = \alpha^2 + \|y\|_2^2. \tag{1.9}$$

1.3 Stabilizer 分解定理

引理 1.2 (固定向量正交流形的分解). 令 $v \neq 0$，$\hat{v}$ 与 U 如上定义。则

$$\mathcal{M}_v = \left\{\hat{v}\hat{v}^\mathsf{T} + URU^\mathsf{T} : R \in O(n-1)\right\}. \tag{1.10}$$

因此 $\mathcal{M}_v$ 与 $O(n-1)$ 同构，并且

$$\dim \mathcal{M}_v = \dim O(n-1) = \frac{(n-1)(n-2)}{2}. \tag{1.11}$$

证明. 先证明右侧包含于左侧。取任意 $R \in O(n-1)$，定义

$$Q = \hat{v}\hat{v}^\mathsf{T} + URU^\mathsf{T}. \tag{1.12}$$

由于 $U^\mathsf{T}\hat{v} = 0$，有

$$Q\hat{v} = \hat{v}\hat{v}^\mathsf{T}\hat{v} + URU^\mathsf{T}\hat{v} = \hat{v}, \tag{1.13}$$

$$Qv = v. \tag{1.14}$$

此外

$$\begin{aligned} Q^\mathsf{T}Q &= (\hat{v}\hat{v}^\mathsf{T} + UR^\mathsf{T}U^\mathsf{T})(\hat{v}\hat{v}^\mathsf{T} + URU^\mathsf{T}) && (1.15)\\ &= \hat{v}\hat{v}^\mathsf{T} + UR^\mathsf{T}RU^\mathsf{T} && (1.16)\\ &= \hat{v}\hat{v}^\mathsf{T} + UU^\mathsf{T} && (1.17)\\ &= I_n. && (1.18) \end{aligned}$$

故 $Q \in \mathcal{M}_v$。

再证明左侧包含于右侧。取任意 $Q \in \mathcal{M}_v$。由 $Qv = v$ 可得 $Q\hat{v} = \hat{v}$。又因 Q 正交，$Q^{-1} = Q^\mathsf{T}$，于是

$$Q\hat{v} = \hat{v} \quad \Longrightarrow \quad Q^\mathsf{T}\hat{v} = \hat{v}. \tag{1.19}$$

对任意 $z \in v^\perp$，有

$$\hat{v}^\mathsf{T}Qz = (Q^\mathsf{T}\hat{v})^\mathsf{T}z = \hat{v}^\mathsf{T}z = 0, \tag{1.20}$$

所以 Q 将 $v^\perp$ 映到 $v^\perp$。因此存在某个线性算子 $R \in \mathbb{R}^{(n-1)\times(n-1)}$，使得

$$QU = UR, \qquad R = U^\top QU. \tag{1.21}$$

由于 Q 在 $v^\perp$ 上仍保持内积，

$$R^\top R = U^\top Q^\top U U^\top Q U. \tag{1.22}$$

注意 QU 的列向量均在 $v^\perp$ 中，所以 $UU^\top QU = QU$。故

$$R^\top R = U^\top Q^\top Q U = U^\top U = I_{n-1}. \tag{1.23}$$

于是 $R \in O(n-1)$。最后，利用 $I = \hat{v}\hat{v}^\top + UU^\top$，

$$\begin{aligned} Q &= Q(\hat{v}\hat{v}^\top + UU^\top) && (1.24)\\ &= Q\hat{v}\hat{v}^\top + QUU^\top && (1.25)\\ &= \hat{v}\hat{v}^\top + URU^\top. && (1.26) \end{aligned}$$

命题得证。 □

注 1.3 (几何解释)**.** $Q \in \mathcal{M}_v$ 在 $\mathrm{span}\{v\}$ 上必须是恒等映射，在 $v^\perp$ 上则可以是任意正交变换。因此 $\mathcal{M}_v$ 的自由度不是 $O(n)$ 的自由度 $n(n-1)/2$，而是 $O(n-1)$ 的自由度 $(n-1)(n-2)/2$。

1.4 Frobenius 最近点投影

现在证明 (1.3) 的闭式解。令

$$B := U^\top A U \in \mathbb{R}^{(n-1)\times(n-1)}. \tag{1.27}$$

我们将看到，A 的 cross-block 项 $\hat{v}\hat{v}^\top AU$ 与 $U^\top A\hat{v}\hat{v}^\top$ 不影响最优 R 的选择；只有 $v^\perp$ 到 $v^\perp$ 的 block B 决定投影。

定理 1.4 (固定向量 Frobenius 投影)**.** 令 $v \neq 0$，$A \in \mathbb{R}^{n\times n}$，$U$ 为 $v^\perp$ 的任意正交基，并令 $B = U^\top AU$。设 B 的奇异值分解为

$$B = W\Sigma Z^\top, \tag{1.28}$$

其中 $W, Z \in O(n-1)$，$\Sigma = \mathrm{diag}(\sigma_1, \ldots, \sigma_{n-1})$，$\sigma_i \geq 0$。则 (1.3) 的一个解为

$$\Pi_v(A) = \hat{v}\hat{v}^\top + UR_\star U^\top, \qquad R_\star = WZ^\top. \tag{1.29}$$

若 B 满秩，则 $R_\star = \mathrm{polar}(B) = B(B^\top B)^{-1/2}$，且解唯一。若 B 奇异，则最近点一般不唯一；此时应理解为正交 *Procrustes* 解或正交 *polar completion*，而不是唯一的矩阵函数值。具体地，若 $\mathrm{rank}(B) = r$，则在零奇异值子空间上可任选 $S_0 \in O(n-1-r)$ 得到一个最优正交补全。

证明. 由引理 1.2，任意 $Q \in \mathcal{M}_v$ 都可写为

$$Q = \hat{v}\hat{v}^\top + URU^\top, \qquad R \in O(n-1). \tag{1.30}$$

因此

$$\begin{aligned} \|A - Q\|_F^2 &= \|A\|_F^2 + \|Q\|_F^2 - 2\operatorname{tr}(Q^\top A) &(1.31)\\ &= \|A\|_F^2 + n - 2\operatorname{tr}(Q^\top A). &(1.32)\end{aligned}$$

最小化 $\|A - Q\|_F^2$ 等价于最大化 $\operatorname{tr}(Q^\top A)$。代入 Q 得

$$\begin{aligned} \operatorname{tr}(Q^\top A) &= \operatorname{tr}\left((\hat{v}\hat{v}^\top + UR^\top U^\top)A\right) &(1.33)\\ &= \operatorname{tr}(\hat{v}\hat{v}^\top A) + \operatorname{tr}(UR^\top U^\top A) &(1.34)\\ &= \operatorname{tr}(\hat{v}\hat{v}^\top A) + \operatorname{tr}(R^\top U^\top AU) &(1.35)\\ &= \operatorname{tr}(\hat{v}\hat{v}^\top A) + \operatorname{tr}(R^\top B). &(1.36)\end{aligned}$$

第一项与 R 无关。因此问题等价于

$$\max_{R \in O(n-1)} \operatorname{tr}(R^\top B). \tag{1.37}$$

令 $B = W\Sigma Z^\top$。对任意 $R \in O(n-1)$，令

$$S := W^\top RZ \in O(n-1). \tag{1.38}$$

则

$$\begin{aligned} \operatorname{tr}(R^\top B) &= \operatorname{tr}(R^\top W\Sigma Z^\top) &(1.39)\\ &= \operatorname{tr}(Z^\top R^\top W\Sigma) &(1.40)\\ &= \operatorname{tr}(S^\top \Sigma) &(1.41)\\ &= \sum_{i=1}^{n-1} \sigma_i S_{ii}. &(1.42)\end{aligned}$$

由于 $S \in O(n-1)$，有 $S_{ii} \le 1$，因此

$$\operatorname{tr}(R^\top B) \le \sum_{i=1}^{n-1} \sigma_i. \tag{1.43}$$

当 $S = I_{n-1}$ 时取等号。此时

$$W^\top RZ = I_{n-1} \quad \Longleftrightarrow \quad R = WZ^\top. \tag{1.44}$$

故 $R_\star = WZ^\top$ 是一个最优解。

若 B 满秩，则全部 $\sigma_i > 0$。达到等号要求 $S_{ii} = 1$ 对所有 i 成立，而正交矩阵若所有对角元素均为 1，则 $S = I$，故最优 R 唯一。此时

$$\operatorname{polar}(B) = B(B^\top B)^{-1/2} = WZ^\top = R_\star. \tag{1.45}$$

若 B 奇异, 则零奇异值对应的子空间上可能存在多个最优 S。更具体地, 若 $\operatorname{rank}(B) = r$, 则在相应 SVD 基下，任意 $\operatorname{diag}(I_r, S_0)$，$S_0 \in O(n-1-r)$，均保持相同目标值。因此最近点可能不唯一。 □

推论 1.5 (投影值与 basis choice 无关). 当 $B = U^\top AU$ 满秩时，$\Pi_v(A)$ 不依赖 $v^\perp$ 正交基 U 的具体选择。奇异情形下最近点可能不唯一，因此不能无条件声称某个数值选择与基无关；但最优值与最优解集合本身与 U 的选择无关。

证明. 令另一个正交基为 $U' = US$，其中 $S \in O(n-1)$。则

$$B' = (U')^\top AU' = S^\top BS. \tag{1.46}$$

满秩时 polar factor 唯一，并满足

$$\operatorname{polar}(S^\top BS) = S^\top \operatorname{polar}(B) S. \tag{1.47}$$

因此

$$U' \operatorname{polar}(B')(U')^\top = US\left(S^\top \operatorname{polar}(B) S\right) S^\top U^\top \tag{1.48}$$

$$= U \operatorname{polar}(B) U^\top. \tag{1.49}$$

故投影值与 U 的选择无关。 □

注 1.6 (该定理的贡献边界). 定理 1.4 并不声称发明了新的 polar decomposition 或新的 Procrustes 理论。它的作用是把经典最近正交矩阵问题限制到固定向量的 stabilizer subgroup 上，并给出一个适合神经网络参数化的闭式投影 primitive。

1.5 保持不变量与等距性质

定理 1.7 (固定向量与全空间等距). 若 $Q \in \mathcal{M}_v$，则

$$Qv = v, \qquad Q^\top v = v, \qquad \|Qx\|_2 = \|x\|_2 \quad \forall x \in \mathbb{R}^n. \tag{1.50}$$

进一步，对任意矩阵 $X \in \mathbb{R}^{n\times d}$，有

$$\|QX\|_F = \|X\|_F, \tag{1.51}$$

且对每个 *channel* $c \in \{1, \dots, d\}$,

$$\|(QX)_{:,c}\|_2 = \|X_{:,c}\|_2. \tag{1.52}$$

证明. $Qv = v$ 来自 $\mathcal{M}_v$ 定义。由于 $Q^\top Q = I$，$Q^{-1} = Q^\top$。由 $Qv = v$ 可得

$$v = Q^{-1}v = Q^\top v. \tag{1.53}$$

对任意 x,

$$\|Qx\|_2^2 = x^\top Q^\top Qx = x^\top x = \|x\|_2^2. \tag{1.54}$$

矩阵情形逐列应用即可。 □

1.6 有限步 Newton-Schulz 实现与误差界

精确投影 (1.29) 需要计算 B 的 polar factor。实际深度学习实现中，常用少量 Newton-Schulz 迭代近似该 polar factor。为避免逻辑混淆，本节明确区分 exact map 与 finite-step implementation。

1.6.1 Newton-Schulz polar iteration

令 $B \in \mathbb{R}^{m\times m}$，$m = n-1$。选择缩放因子 $\gamma > 0$，令

$$X_0 = B/\gamma. \tag{1.55}$$

常见的 Newton-Schulz 迭代为

$$X_{k+1} = \frac{3}{2}X_k - \frac{1}{2}X_kX_k^\top X_k = \frac{1}{2}X_k(3I - X_k^\top X_k). \tag{1.56}$$

当 B 满秩且缩放使 X_0 的奇异值位于合适收敛区间时，X_k 收敛到 B 的 polar factor。一个保守实践是取

$$\gamma \geq \|B\|_2, \tag{1.57}$$

使 $\sigma_{\max}(X_0) \leq 1$。若 B 满秩，则全部奇异值为正，迭代会将奇异值推向 1。

注 1.8 (有限步不等于精确正交). 有限步 X_K 一般不满足 $X_K^\top X_K = I$，因此不能把 practical Iso-NS 直接称为精确投影。严谨写法应为：精确算法使用 $R_\star = \mathrm{polar}(B)$；工程实现使用 $R_K = X_K$ 近似 $R_\star$。

1.6.2 近似投影的结构误差

定义有限步近似

$$Q_K := \hat{v}\hat{v}^\top + UR_KU^\top, \qquad R_K := X_K. \tag{1.58}$$

即使 R_K 不是精确正交，Q_K 仍然精确固定 v。

命题 1.9 (有限步 NS 的不变量与等距误差)**.** 令 Q_K 如 (1.58)。则

$$Q_K v = v, \qquad Q_K^\top v = v. \tag{1.59}$$

若

$$\left\| R_K^\top R_K - I \right\|_2 \le \varepsilon, \tag{1.60}$$

则

$$\left\| Q_K^\top Q_K - I \right\|_2 \le \varepsilon. \tag{1.61}$$

并且对任意 $x \in \mathbb{R}^n$,

$$\left| \|Q_K x\|_2^2 - \|x\|_2^2 \right| \le \varepsilon \, \|(I - P_v)x\|_2^2 \le \varepsilon \, \|x\|_2^2 . \tag{1.62}$$

证明. 首先，因 $U^\top v = 0$ 且 $\hat{v}\hat{v}^\top v = v$，有

$$Q_K v = (\hat{v}\hat{v}^\top + U R_K U^\top) v = v. \tag{1.63}$$

同理

$$Q_K^\top v = (\hat{v}\hat{v}^\top + U R_K^\top U^\top) v = v. \tag{1.64}$$

其次，利用 $U^\top \hat{v} = 0$,

$$\begin{aligned} Q_K^\top Q_K &= (\hat{v}\hat{v}^\top + U R_K^\top U^\top)(\hat{v}\hat{v}^\top + U R_K U^\top) && (1.65) \\ &= \hat{v}\hat{v}^\top + U R_K^\top R_K U^\top. && (1.66) \end{aligned}$$

因此

$$Q_K^\top Q_K - I = U(R_K^\top R_K - I)U^\top. \tag{1.67}$$

由于 U 列正交，operator norm 不增，得 (1.61)。

最后，将 x 分解为 $x = \alpha \hat{v} + U y$，其中 $y = U^\top x$。则

$$\begin{aligned} \|Q_K x\|_2^2 &= \|\alpha \hat{v} + U R_K y\|_2^2 && (1.68) \\ &= \alpha^2 + y^\top R_K^\top R_K y, && (1.69) \end{aligned}$$

而

$$\|x\|_2^2 = \alpha^2 + y^\top y. \tag{1.70}$$

故

$$\begin{aligned} \left| \|Q_K x\|_2^2 - \|x\|_2^2 \right| &= \left| y^\top (R_K^\top R_K - I) y \right| && (1.71) \\ &\le \varepsilon \, \|y\|_2^2 && (1.72) \\ &= \varepsilon \, \|(I - P_v)x\|_2^2 . && (1.73) \end{aligned}$$

证毕。 □

1.7 非负性、正交性与随机性的不可兼得

IsoHC 与 mHC 的核心差异并不是单纯工程选择，而是几何约束的不可兼得：若同时要求 signed-free convex mixing 与 exact isometry，可行集合会退化为置换矩阵。

命题 1.10 (非负正交随机矩阵退化为置换矩阵)**.** 若 $H \in \mathbb{R}^{n\times n}$ 满足

$$H \geq 0, \qquad H\mathbf{1} = \mathbf{1}, \qquad H^\top H = I, \tag{1.74}$$

则 H 是置换矩阵。

证明. 由 $H^\top H = I$ 且 H 为方阵可知 H 可逆，且 $H^{-1} = H^\top$。因此 $HH^\top = I$，即每一行向量 $r_i^\top$ 都满足

$$\|r_i\|_2 = 1. \tag{1.75}$$

又由 $H \geq 0$ 与 $H\mathbf{1} = \mathbf{1}$，每一行满足

$$r_i \geq 0, \qquad \|r_i\|_1 = \sum_j r_{ij} = 1. \tag{1.76}$$

对任意非负向量 r，若 $\|r\|_1 = 1$，则

$$\|r\|_2^2 = \sum_j r_j^2 \leq \left(\sum_j r_j\right)^2 = 1, \tag{1.77}$$

且等号成立当且仅当至多一个分量非零。这里又有 $\|r_i\|_2 = 1$, 所以每一行必须是 one-hot 向量。由于不同行互相正交，这些 one-hot 的位置互不相同。因此 H 是置换矩阵。 □

注 1.11 (对 mHC 与 IsoHC 的含义)**.** Birkhoff/doubly stochastic 约束允许连续的非负 convex mixing，但一般不保证在 $\mathbf{1}^\perp$ 上等距；固定均值的正交约束保证 exact isometry，但除置换外必须允许 signed mixing。这是两类约束之间的基本 trade-off。

1.8 多不变量方向的推广

单向量情形可自然推广到固定一个 r 维子空间。设 $C \in \mathbb{R}^{n\times r}$ 列正交，表示需要逐点固定的 invariant subspace：

$$C^\top C = I_r. \tag{1.78}$$

定义

$$\mathcal{M}_C := \{Q \in O(n) : QC = C\}. \tag{1.79}$$

令 $U \in \mathbb{R}^{n\times(n-r)}$ 是 $\mathrm{col}(C)^\perp$ 的正交基。完全相同的证明给出

$$\mathcal{M}_C = \{CC^\top + URU^\top : R \in O(n-r)\} \tag{1.80}$$

以及

$$\Pi_C(A) = CC^\mathsf{T} + U\,\mathrm{polar}(U^\mathsf{T}AU)U^\mathsf{T}. \tag{1.81}$$

这说明本文的数学 primitive 并不限于固定一个向量，也可用于固定多个线性守恒方向的模型。

第二章　IsoHC：从通用投影到残差流等距混合

2.1　Hyper-Connections 中的稳定性问题

考虑 n 条 residual stream，每层表示为

$$X_l \in \mathbb{R}^{n\times d}. \tag{2.1}$$

抽象地，Hyper-Connections 中 residual stream 的线性传播部分可写为

$$X_{l+1} = H_l^{\text{res}} X_l + \text{nonlinear/update terms}. \tag{2.2}$$

如果只看 residual-only linearization，则

$$X_L = H_{L-1}^{\text{res}} \cdots H_1^{\text{res}} H_0^{\text{res}} X_0. \tag{2.3}$$

当 H_l^{res} 不受约束时，深层乘积可能导致范数爆炸、衰减或 stream collapse。

mHC 使用 Birkhoff polytope 约束, 使 mixing matrix 非负且 doubly stochastic, 从而保留全局均值并限制扩张。但该约束代表的是 diffusion-like mixing, 不保证在 mean-zero 子空间上保持能量。IsoHC 的出发点是：在 residual highway 上，除了保留均值，还希望保留 stream-wise energy。

2.2　IsoHC 流形定义

取不变量方向

$$v = \mathbf{1} = (1, 1, \ldots, 1)^{\mathsf{T}} \in \mathbb{R}^n, \qquad e_0 = \frac{\mathbf{1}}{\sqrt{n}}. \tag{2.4}$$

注意这里必须是 $\mathbf{1}/\sqrt{n}$，而不是 $\mathbf{1}/n$，因为 e_0 需要是单位向量。

IsoHC residual mixing manifold 定义为

$$\mathcal{M}_{\text{iso}} := \{H \in \mathbb{R}^{n\times n} : H^{\mathsf{T}} H = I,\ H\mathbf{1} = \mathbf{1}\}. \tag{2.5}$$

这正是第一章中 $\mathcal{M}_v$ 在 $v = \mathbf{1}$ 时的特例。若 $U \in \mathbb{R}^{n\times(n-1)}$ 是 $\mathbf{1}^\perp$ 的正交基，则

$$H \in \mathcal{M}_{\text{iso}} \quad \Longleftrightarrow \quad H = e_0 e_0^\top + URU^\top, \qquad R \in O(n-1). \tag{2.6}$$

因此

$$\dim \mathcal{M}_{\text{iso}} = \frac{(n-1)(n-2)}{2}. \tag{2.7}$$

2.3 IsoHC 的精确不变量

定理 2.1 (IsoHC 的 mean 与 energy 保持)**.** 令 $H \in \mathcal{M}_{\text{iso}}$，$X \in \mathbb{R}^{n\times d}$。定义 *stream mean* 为

$$\mu(X) := \frac{1}{n}\mathbf{1}^\top X \in \mathbb{R}^{1\times d}. \tag{2.8}$$

则

$$\mu(HX) = \mu(X). \tag{2.9}$$

并且对任意 *channel* c,

$$\|(HX)_{:,c}\|_2 = \|X_{:,c}\|_2 . \tag{2.10}$$

因此

$$\|HX\|_F = \|X\|_F . \tag{2.11}$$

证明. 由 $H\mathbf{1} = \mathbf{1}$ 和 $H^\top H = I$ 可知

$$H^\top \mathbf{1} = \mathbf{1}. \tag{2.12}$$

转置得

$$\mathbf{1}^\top H = \mathbf{1}^\top. \tag{2.13}$$

因此

$$\mu(HX) = \frac{1}{n}\mathbf{1}^\top HX = \frac{1}{n}\mathbf{1}^\top X = \mu(X). \tag{2.14}$$

注意：这里不能只从 $H\mathbf{1} = \mathbf{1}$ 直接推出 $\mathbf{1}^\top H = \mathbf{1}^\top$；关键还需要正交性。

对每个 channel c，令 $x = X_{:,c}$。由 $H^\top H = I$,

$$\|Hx\|_2^2 = x^\top H^\top Hx = x^\top x = \|x\|_2^2 . \tag{2.15}$$

逐列相加得到 Frobenius norm 保持。 □

2.4 Iso-NS: stabilizer polar projection 的实现

给定 unconstrained residual parameter $\widetilde{H} \in \mathbb{R}^{n\times n}$，IsoHC 的 exact projection 是

$$\Pi_{\mathbf{1}}(\widetilde{H}) = e_0 e_0^\top + U \operatorname{polar}(U^\top \widetilde{H} U)U^\top. \tag{2.16}$$

为便于反向传播和避免每步 SVD，可使用 Newton-Schulz 近似 polar factor。

Algorithm 1 Iso-NS: fixed-mean isometric Newton-Schulz projection

Require: Unconstrained matrix $\widetilde{H} \in \mathbb{R}^{n\times n}$; orthonormal basis $U \in \mathbb{R}^{n\times(n-1)}$ of $\mathbf{1}^{\perp}$; iterations K; scale $\gamma > 0$.

Ensure: Approximate fixed-mean isometric matrix H_K.

1: $e_0 \leftarrow \mathbf{1}/\sqrt{n}$.
2: $B \leftarrow U^{\top}\widetilde{H}U$.
3: $X_0 \leftarrow B/\gamma$.
4: **for** $k = 0, 1, \ldots, K-1$ **do**
5: $\quad X_{k+1} \leftarrow \frac{3}{2}X_k - \frac{1}{2}X_k X_k^{\top} X_k$.
6: **end for**
7: $R_K \leftarrow X_K$.
8: $H_K \leftarrow e_0 e_0^{\top} + U R_K U^{\top}$.
9: **return** H_K.

注 2.2 (exact 与 practical 两个版本)**.** 若第 6 行取 $R = \mathrm{polar}(B)$，则输出 H 精确属于 $\mathcal{M}_{\mathrm{iso}}$。若第 6 行取有限步 $R_K = X_K$，则 $H_K\mathbf{1} = \mathbf{1}$ 与 $H_K^{\top}\mathbf{1} = \mathbf{1}$ 仍然精确成立，但正交性与能量保持只在误差界内成立。

2.5 Iso-NS 的误差传递到 IsoHC

将命题 1.9 应用于 $v = \mathbf{1}$，得到如下直接结论。

推论 2.3 (有限步 Iso-NS 的 mean 精确保持与 energy 近似保持)**.** 令

$$H_K = e_0 e_0^{\top} + U R_K U^{\top}. \tag{2.17}$$

则

$$H_K\mathbf{1} = \mathbf{1}, \qquad H_K^{\top}\mathbf{1} = \mathbf{1}. \tag{2.18}$$

因此对任意 $X \in \mathbb{R}^{n\times d}$,

$$\mu(H_K X) = \mu(X) \tag{2.19}$$

精确成立。若

$$\left\| R_K^{\top} R_K - I \right\|_2 \le \varepsilon, \tag{2.20}$$

则对任意 *channel* $x = X_{:,c}$,

$$\left| \|H_K x\|_2^2 - \|x\|_2^2 \right| \le \varepsilon \left\| (I - e_0 e_0^{\top}) x \right\|_2^2 \le \varepsilon \|x\|_2^2 . \tag{2.21}$$

2.6 残差路径上的梯度保持

考虑 residual-only linearization：

$$X_{l+1} = H_l X_l, \qquad H_l \in \mathcal{M}_{\text{iso}}. \tag{2.22}$$

对 loss $\mathcal{L}$，令

$$G_l := \frac{\partial \mathcal{L}}{\partial X_l} \in \mathbb{R}^{n\times d}. \tag{2.23}$$

链式法则给出

$$G_l = H_l^{\mathsf{T}} G_{l+1}. \tag{2.24}$$

由于 H_l 正交,

$$\|G_l\|_F = \|G_{l+1}\|_F. \tag{2.25}$$

于是对深层乘积有

$$\|G_0\|_F = \|G_L\|_F. \tag{2.26}$$

注 2.4 (严格适用范围). 式 (2.26) 是 residual-only path 的结论。完整 Transformer block 还包含 nonlinear/update terms,其 Jacobian 会额外贡献项;IsoHC 的理论保证是 residual mixing 部分不会引入额外范数漂移，而不是声称整个网络 Jacobian 全局正交。

若使用 finite-step $H_{l,K}$，并且每层满足

$$\left\|H_{l,K}^{\mathsf{T}} H_{l,K} - I\right\|_2 \le \varepsilon_l, \tag{2.27}$$

则单层梯度满足

$$\left\|H_{l,K}^{\mathsf{T}} G\right\|_F^2 \le (1+\varepsilon_l)\|G\|_F^2. \tag{2.28}$$

因此可得到粗略乘积上界

$$\|G_0\|_F \le \left(\prod_{l=0}^{L-1}\sqrt{1+\varepsilon_l}\right)\|G_L\|_F. \tag{2.29}$$

类似地若 $H_{l,K}^{\mathsf{T}} H_{l,K} \succeq (1-\varepsilon_l)I$，则有对应下界。这说明 finite-step NS 的误差需要被监控或控制；不能在理论上直接当作 exact isometry。

2.7 与 mHC 的几何差异

mHC 使用 doubly stochastic residual mixing：

$$\mathcal{B} = \{H \in \mathbb{R}^{n\times n} : H\mathbf{1} = \mathbf{1},\ \mathbf{1}^{\mathsf{T}} H = \mathbf{1}^{\mathsf{T}},\ H \ge 0\}. \tag{2.30}$$

它的优势是每一行/列都有 convex mixing 解释，并且保留 stream mean。但它不强制 $H^{\mathsf{T}} H = I$，因此不保证 residual path 上的 exact energy preservation。

IsoHC 使用

$$\mathcal{M}_{\text{iso}} = \{H \in O(n) : H\mathbf{1} = \mathbf{1}\}. \tag{2.31}$$

它保留 mean 与 energy，但除了置换矩阵以外必须允许 signed coefficients。命题 1.10 说明：若同时要求非负、行随机和正交，那么只能得到置换矩阵。

因此，mHC 与 IsoHC 的区别可以概括为表 2.1。

表 2.1: mHC 与 IsoHC 的几何比较

性质	mHC / Birkhoff	IsoHC / fixed-mean orthogonal
约束集合	doubly stochastic polytope	stabilizer subgroup of $\mathbf{1}$ in $O(n)$
mean preservation	是	是
energy preservation	不保证	精确保证，若用 exact polar
系数符号	非负	可正可负
几何行为	diffusion-like convex mixing	rotation/reflection-like isometric mixing
退化边界	可连续扩散	若再要求非负则退化为 permutation
核心风险	mean-zero 子空间可能耗散	signed mixing 可能产生局部 cancellation

2.8 论文中建议的理论表述

建议在论文贡献中将 Algorithm 1 分成两层表述。

数学 primitive. We formulate invariant-preserving neural mixing as a fixed-vector orthogonal projection problem and derive the stabilizer polar projection

$$\Pi_v(A) = \hat{v}\hat{v}^\top + U\,\mathrm{polar}(U^\top AU)U^\top. \tag{2.32}$$

IsoHC instantiation. For Hyper-Connections, taking $v = \mathbf{1}$ yields a residual mixing matrix that preserves stream mean and channel-wise stream energy. A differentiable Newton-Schulz implementation gives an efficient approximation for small stream counts $n \in \{4, 8\}$.

2.9 需要在实验或实现中验证的点

数学推导给出的是清晰的理想保证。实际论文中还应验证以下事项:

(1) **NS orthogonality error:** 记录 $\left\|R_K^\top R_K - I\right\|_2$ 或 $\left\|H_K^\top H_K - I\right\|_F$，确认有限步近似足够接近 exact isometry。

(2) **mean preservation:** 验证 $\left\|\mathbf{1}^\top H_K - \mathbf{1}^\top\right\|$ 与 $\|H_K\mathbf{1} - \mathbf{1}\|$，理论上由构造精确保留，数值上应接近机器精度。

(3) **gradient profile:** 在 residual-only 或近似 residual-dominant 路径上记录 $\|G_l\|_F$ 随深度的变化。

(4) **signed cancellation:** 因 IsoHC 允许负系数，应监控 stream cosine similarity、activation variance 与 element-wise cancellation 指标。

(5) **basis implementation:** U 应固定为一个数值稳定的 $\mathbf{1}^\perp$ 正交基；理论上投影与 U 的选择无关，但有限精度下不同 U 可能带来微小差异。

2.10 本推导没有声称的内容

为避免过度宣称，建议论文中明确以下边界:

(1) 本文没有发明 polar decomposition 或 classical Procrustes theorem；贡献是将其组织为 fixed-vector stabilizer projection，并用于 invariant-preserving neural mixing。

(2) Exact energy preservation 只对 exact polar projection 成立；有限步 Newton-Schulz 需要误差界支持。

(3) Residual-only gradient preservation 不等于完整 Transformer block 的全局 Jacobian 正交。

(4) IsoHC 不保持非负性；若任务必须保持概率单纯形上的非负概率，Birkhoff 或 Markov 类型约束可能更合适。

(5) 当前理论基于 Euclidean metric。若需要保持 weighted norm $x^\top Gx$，需要推广到 G-orthogonal 约束 $Q^\top GQ = G$。

结论

本文补齐了 IsoHC 背后的通用数学推导。核心结论是：Algorithm 1 不应只被描述为 HC 的工程实现，而应被表述为一个 fixed-vector orthogonal projection primitive。其 exact 版本是

$$\Pi_v(A) = \hat{v}\hat{v}^\top + U\,\mathrm{polar}(U^\top AU)U^\top, \tag{2.33}$$

它是 Frobenius 范数下到

$$\mathcal{M}_v = \{Q \in O(n) : Qv = v\} \tag{2.34}$$

的最近点投影。对 IsoHC，取 $v = \mathbf{1}$ 即得保持 residual stream mean 的正交混合矩阵。该结构严格保留 mean 与 energy；有限步 Newton-Schulz 版本则精确保留 mean，并在可量化误差内近似保持 energy。

因此，最稳妥的论文定位是：

> IsoHC identifies fixed-vector orthogonal projection as the right geometric primitive for invariant-preserving residual mixing, and implements it efficiently through a differentiable Newton-Schulz approximation.